Informe de Avance

Proyecto Final Data Science — Producción No Convencional, Cuenca Neuquina

Alumnos	Cristian Alejandro Aguilera, Abigail Roxana Vicentelo, Ian Lionel Tapias Díaz
Programa	Data Science — Energía Digital 2026 (Fundación YPF - Jump)
Repositorio GitHub	https://github.com/cristian-aguilera-ing/proyecto-ds-ypf.git
Versión	Versión 2 — Cuenca Neuquina, petróleo y gas (actualizado al 23 de octubre de 2026)

1. Estado actual

La versión 2 del proyecto está completa: datos limpios, cuatro modelos supervisados, clustering, explicabilidad, API, frontend, Docker Compose, tests y documentación. Se presenta como pull request (rama feature/v2-neuquina) sobre la versión 1 del repositorio.

Etapa	Estado	Entregable
Pre-Entrega 1 — definición	Cerrada	docs/Pre_Entrega_1_YPF
Pre-Entrega 2 — EDA y limpieza	Cerrada	notebooks 01 y 02, src/ypf_ds/data/
Pre-Entrega 3 — supervisado	Cerrada	notebook 03, src/ypf_ds/models/train.py
Pre-Entrega 4 — no supervisado	Cerrada	notebook 04, src/ypf_ds/models/cluster.py
Explicabilidad	Cerrada	notebook 05 y SHAP por predicción en la API
Entrega final — API, frontend y Docker	Funcionando	api/, frontend/, compose.yaml
Tests automáticos	15 tests pasan	tests/
Presentación oral	Pendiente	—

2. Qué cambió de la versión 1 a la versión 2

Aspecto	Versión 1	Versión 2
Población	4 cuencas	Solo Cuenca Neuquina (96 % de los datos)
Fluidos	Solo petróleo	Petróleo y gas, con modelos separados
Horizonte	1 mes	1 a 12 meses (pozo existente) y 24 meses (pozo nuevo)
Pozo nuevo	No	Curva tipo desde atributos conocidos antes de perforar
Incertidumbre	No	Bandas P10–P90 con regresión por cuantiles
Baselines	Repetir el mes anterior	Persistencia, curva de declinación Arps y curva mediana
Datos	pandas, CSV	Polars + DuckDB, Parquet; grilla mensual continua
Algoritmos comparados	XGBoost y LightGBM	Ridge, árbol, KNN, Random Forest, MLP, XGBoost y LightGBM
Clustering	4 variables resumen, K-Means	Forma de curva + SVD, K-Means vs DBSCAN
Seguimiento de experimentos	No	MLflow
Frontend	Formulario de pruebas	Dos modos, gráficos con bandas, SHAP, cluster y

		avisos
Tests	No	15 tests (limpieza, ausencia de fuga, API)

3. Resultados principales (test 2024–2025)

- Pozo existente, petróleo: R^2 0,730 (persistencia 0,246); a 1 mes R^2 0,889, a 12 meses 0,630.
- Pozo existente, gas: R^2 0,779 (persistencia 0,536).
- Backtest a 12 meses desde diciembre 2023: WAPE 0,357 contra 0,583 de Arps (petróleo).
- Pozo nuevo, acumulada 12 meses: R^2 0,448 en petróleo y 0,860 en gas, contra -0,282 y 0,724 de la curva mediana.
- Con el mismo alcance que la v1 (1 mes, petróleo): R^2 0,906, equivalente al 0,907 de la v1.

4. Decisiones técnicas relevantes

- **Target en volumen:** modelar en log subestimaba la producción total en ~19–25 %; se pasó a minimizar el error en m^3.
- **Validación estrictamente temporal:** train ≤ 2022, validación 2023, test 2024–2025; en el modo B, por año de inicio del pozo.
- **Capítulo IV:** integrado en la limpieza; sus variables se evalúan en cada entrenamiento y hoy no se usan porque no mejoran la validación.
- **Honestidad de la comparación:** Random Forest empata con LightGBM en la muestra; se eligió LightGBM por escala, cuantiles y pesos, y se documentó.

5. Próximos pasos

- Revisión del pull request por el equipo y merge a main.
- Presentación oral de 15 minutos con demo en vivo.
- Opcional: deploy de la API en Render o Hugging Face Spaces.
- Mejora futura: incorporar largo de rama lateral y etapas de fractura si se consiguen datos públicos.