Informe de Avance

Proyecto Final Data Science — Producción No Convencional, Cuenca Neuquina

Alumnos	Cristian Alejandro Aguilera, Abigail Roxana Vicentelo, Ian Lionel Tapias Díaz
Programa	Data Science — Energía Digital 2026 (Fundación YPF - Jump)
Repositorio GitHub	https://github.com/cristian-aguilera-ing/proyecto-ds-ypf.git
Versión	Versión 2 — Cuenca Neuquina, petróleo y gas (actualizado al 28 de octubre de 2026)

1. Estado actual

La versión 2 del proyecto está completa e integrada en main: datos limpios, cuatro modelos supervisados, clustering, explicabilidad, API, frontend con dashboard de métricas, Docker Compose, 28 tests y documentación. Además se atendieron las dos recomendaciones de la devolución de la pre-entrega.

Etapa	Estado	Entregable
Pre-Entrega 1 — definición	Cerrada	docs/Pre_Entrega_1_YPF
Pre-Entrega 2 — EDA y limpieza	Cerrada	notebooks 01 y 02, src/ypf_ds/data/
Pre-Entrega 3 — supervisado	Cerrada	notebook 03, src/ypf_ds/models/train.py
Pre-Entrega 4 — no supervisado	Cerrada	notebook 04, src/ypf_ds/models/cluster.py
Explicabilidad	Cerrada	notebook 05 y SHAP por predicción en la API
Entrega final — API, frontend y Docker	Funcionando	api/, frontend/ (3 pestañas, dashboard de métricas), compose.yaml
Tests automáticos	28 tests pasan	tests/
Devolución de la pre-entrega	Atendida	Validación de coordenadas y memoria de la API
Presentación oral	Pendiente	—

2. Qué cambió de la versión 1 a la versión 2

Aspecto	Versión 1	Versión 2
Población	4 cuencas	Solo Cuenca Neuquina (96 % de los datos)
Fluidos	Solo petróleo	Petróleo y gas, con modelos separados
Horizonte	1 mes	1 a 12 meses (pozo existente) y 24 meses (pozo nuevo)
Pozo nuevo	No	Curva tipo desde atributos conocidos antes de perforar
Incertidumbre	No	Bandas P10–P90 con regresión por cuantiles
Baselines	Repetir el mes anterior	Persistencia, curva de declinación Arps y curva mediana
Datos	pandas, CSV	Polars + DuckDB, Parquet; grilla mensual continua
Algoritmos comparados	XGBoost y LightGBM	Ridge, árbol, KNN, Random Forest, MLP, XGBoost y LightGBM
Clustering	4 variables resumen, K-Means	Forma de curva + SVD, K-Means vs DBSCAN

Seguimiento de experimentos	No	MLflow
Frontend	Formulario de pruebas	Tres pestañas (existente, nuevo y métricas), gráficos con bandas, SHAP, cluster, avisos, guía de lectura y modo claro / oscuro
Tests	No	28 tests (limpieza, ausencia de fuga, API y validación de entradas)

3. Resultados principales (test 2024–2025)

- Pozo existente, petróleo: R^2 0,730 (persistencia 0,246); a 1 mes R^2 0,889, a 12 meses 0,630.
- Pozo existente, gas: R^2 0,779 (persistencia 0,536).
- Backtest a 12 meses desde diciembre 2023: WAPE 0,357 contra 0,583 de Arps (petróleo).
- Pozo nuevo, acumulada 12 meses: R^2 0,448 en petróleo y 0,860 en gas, contra -0,282 y 0,724 de la curva mediana.
- Con el mismo alcance que la v1 (1 mes, petróleo): R^2 0,906, equivalente al 0,907 de la v1.

4. Decisiones técnicas relevantes

- **Target en volumen:** modelar en log subestimaba la producción total en ~19–25 %; se pasó a minimizar el error en m^3.
- **Validación estrictamente temporal:** train ≤ 2022, validación 2023, test 2024–2025; en el modo B, por año de inicio del pozo.
- **Capítulo IV:** integrado en la limpieza; sus variables se evalúan en cada entrenamiento y hoy no se usan porque no mejoran la validación.
- **Honestidad de la comparación:** Random Forest empata con LightGBM en la muestra; se eligió LightGBM por escala, cuantiles y pesos, y se documentó.

5. Mejoras posteriores a la devolución

- **Validación de coordenadas:** la API rechaza pozos nuevos fuera de la Cuenca Neuquina (lat −40 a −34, lon −70,5 a −67, a partir de los pozos reales con medio grado de margen) y avisa si el pozo queda a más de 50 km del área elegida.
- **Memoria de la API:** medida con docker stats, bajó de 921 MB a 336 MB. Los .joblib pesan 7,4 MB y no eran la causa; el consumo venía de usar 2 workers de uvicorn (cada uno con su copia de modelos y datos) y de los hilos de Polars al leer el panel. Se dejó 1 worker, Polars con 2 hilos y un tope de 1 GB.
- **Frontend:** rediseño con modo claro / oscuro, pestaña “Métricas del modelo” con 8 gráficos y una guía “Cómo leer este gráfico” junto a cada uno.
- **Correcciones:** los pozos sin producción en su último mes ya no rompen la pantalla, y el ejemplo de la API usa un idpozo existente.

6. Próximos pasos

- Ensayar la demo con pozos de ejemplo: LCa-3039 (pozo existente) y un pozo nuevo en Loma Campana.
- Presentación oral de 15 minutos con demo en vivo.
- Opcional: deploy de la API en Render o Hugging Face Spaces.
- Mejora futura: incorporar largo de rama lateral y etapas de fractura si se consiguen datos públicos.