Pre-Entrega 1 — Definición del Problema y Dataset

Proyecto Final Integrador — Data Science 2026

Alumnos	Cristian Alejandro Aguilera, Abigail Roxana Vicentelo, Ian Lionel Tapias Díaz
Programa	Data Science — Energía Digital 2026 (Fundación YPF - Jump)
Repositorio GitHub	https://github.com/cristian-aguilera-ing/proyecto-ds-ypf.git
Versión	Versión 2 — Cuenca Neuquina, petróleo y gas (actualizado al 23 de octubre de 2026)

1. Definición del problema

1.1 Título del proyecto

Predicción de la producción de petróleo y gas no convencional en la Cuenca Neuquina (Vaca Muerta y formaciones tight).

1.2 Planteamiento del problema

La producción de los pozos no convencionales (shale y tight) presenta curvas de declinación pronunciadas y muy heterogéneas: un pozo puede perder más de la mitad de su producción en el primer año, y dos pozos de la misma formación pueden producir órdenes de magnitud distintos. Anticipar esa curva es clave para planificar perforación, instalaciones de superficie, transporte y proyección de reservas.

El proyecto responde dos preguntas concretas, para petróleo y para gas por separado:

- **Pozo existente:** dado un pozo que ya produce, ¿cuánto va a producir en cada uno de los próximos 1 a 12 meses?
- **Pozo nuevo:** dadas las características conocidas antes de perforar (formación, zona, profundidad, tipo de pozo, operadora, año), ¿qué curva de producción se espera en sus primeros 24 meses?

1.3 Alcance: solo Cuenca Neuquina

Se trabaja únicamente con la Cuenca Neuquina, que concentra el 96 % de los registros y casi toda la producción no convencional del país. Las otras cuencas (Austral, Golfo San Jorge, Noroeste) tienen muy pocos pozos y una geología distinta: mezclarlas agrega ruido sin aportar datos suficientes para aprender su comportamiento.

1.4 Objetivos

- **General:** construir un pipeline reproducible de Data Science, desde los datos crudos hasta una aplicación web, que pronostique la producción de petróleo y gas de pozos no convencionales de la Cuenca Neuquina.
- **Supervisado:** entrenar modelos de regresión (LightGBM, comparado con Ridge, árbol de decisión, KNN, Random Forest, MLP y XGBoost) separados para petróleo y gas, con bandas de incertidumbre P10–P90, y superar a los baselines de la industria (repetir el último mes y la curva de declinación de Arps).
- **No supervisado:** agrupar los pozos por la forma de su curva de producción (SVD + K-Means, comparado con DBSCAN).
- **Explicabilidad:** explicar cada predicción con SHAP.
- **Producto:** exponer los modelos con una API FastAPI y un frontend con formulario, todo levantado con Docker Compose.

1.5 Relevancia

Vaca Muerta es el principal desarrollo de hidrocarburos no convencionales de la Argentina y el eje de la estrategia de YPF. Estimar la producción de un pozo antes de perforarlo, o anticipar la declinación de los pozos en producción, aporta valor directo a la planificación operativa y de inversión.

2. Selección del dataset

2.1 Fuentes

- **Principal:** "Producción de Pozos de Gas y Petróleo No Convencional", del dataset "Producción de petróleo y gas por pozo (Capítulo IV)" de la Secretaría de Energía de la Nación (datos.energia.gob.ar, licencia CC-BY-4.0). Ya viene filtrado a pozos shale y tight.
- **Complementaria:** "Capítulo IV — Pozos" (capitulo-iv-pozos.csv): padrón de 85.611 pozos con cota, profundidad y fechas de perforación y terminación.

Descarga del dataset principal (copiar y pegar en el navegador):

```
http://datos.energia.gob.ar/dataset/c846e79c-026c-4040-897f-1ad3543b407c/resource/b5b58cdc-9e07-41f9-b392-fb9ec68b0725/download/produccin-de-pozos-de-gas-y-petrleo-no-convencional.csv
```

2.2 Descripción general

Característica	Valor
Filas / columnas (crudo)	421.046 × 40
Filas de la Cuenca Neuquina	404.037 (4.862 pozos)
Cobertura temporal	enero 2006 – julio 2026, mensual
Granularidad	un registro por pozo y mes
Variables clave	idpozo, sigla, prod_pet (m^3), prod_gas (miles de m^3), prod_agua, tef (días efectivos), formacion, areayacimiento, empresa, profundidad, coordenadas, tipopozo, sub_tipo_recurso
Dataset de trabajo (después de la limpieza)	382.992 filas pozo-mes, 4.682 pozos productores

2.3 Justificación

- Dataset oficial, público y de actualización mensual: trazabilidad de la fuente.
- 20 años de historia y más de 400 mil registros: volumen suficiente para modelos de árboles.
- Incluye geología, ubicación y operadora, que son las variables mínimas para modelar productividad.
- Tiene anomalías reales (profundidades imposibles, coordenadas invertidas, meses faltantes, días efectivos mal cargados), lo que obliga a un proceso de limpieza genuino.

3. Configuración del repositorio y del entorno

3.1 Estructura

Carpeta / archivo	Contenido
data/raw/	CSV originales (no se versionan)
data/processed/	panel_neuquina.parquet y pozos_neuquina.parquet (dataset de trabajo)
notebooks/	01_eda · 02_limpieza_transformacion · 03_modelado_supervisado ·

	04_clustering_svd · 05_explicabilidad_shap
src/ypf_ds/	config.py, data/ (load, clean), features/build.py, models/ (train, predict, baselines, evaluate, cluster)
api/	app.py (FastAPI), model.py (carga de modelos), schemas.py (validación Pydantic)
frontend/	formulario web (HTML + JavaScript + Chart.js)
models/	4 modelos LightGBM, clustering y metadata.json
docker/, compose.yaml	imágenes de la API y del frontend; Docker Compose
tests/	tests automáticos de limpieza, ausencia de fuga de datos y API
docs/	entregas, guía del proyecto y guía del frontend

3.2 Entorno

- Python 3.14 en un entorno virtual (.venv), con las versiones fijadas en requirements.txt (proyecto completo) y requirements-api.txt (imagen de la API).
- Librerías principales: Polars y DuckDB (datos), scikit-learn, LightGBM, XGBoost, Optuna, SHAP, MLflow, FastAPI.
- Docker Compose levanta la API (puerto 8000) y el frontend (puerto 8080) con un solo comando.

4. Metodología prevista

1. EDA y limpieza (Pre-Entrega 2).
2. Feature engineering y modelado supervisado con validación temporal (Pre-Entrega 3).
3. Clustering, reducción de dimensionalidad y explicabilidad (Pre-Entrega 4).
4. API, frontend, Docker, README y presentación (Entrega Final).