Pre-Entrega 3 — Feature Engineering y Modelado Supervisado

Proyecto Final Integrador — Data Science 2026

Alumnos	Cristian Alejandro Aguilera, Abigail Roxana Vicentelo, Ian Lionel Tapias Díaz
Programa	Data Science — Energía Digital 2026 (Fundación YPF - Jump)
Repositorio GitHub	https://github.com/cristian-aguilera-ing/proyecto-ds-ypf.git
Versión	Versión 2 — Cuenca Neuquina, petróleo y gas (actualizado al 23 de octubre de 2026)

1. Planteo del problema de regresión

	Modo A — pozo existente	**Modo B — pozo nuevo**
Fila de entrenamiento	(pozo, mes de origen t, horizonte h = 1…12)	(pozo, mes de vida 1…24)
Información disponible	Historia del pozo hasta t	Solo atributos conocidos antes de perforar
Target puntual	Ratio q[t+h] / q[t], ponderado por $q[t]^2$	Producción del mes en volumen
Salida	Pronóstico mensual P10 / P50 / P90	Curva tipo de 24 meses P10 / P50 / P90

Cada modo se entrena por separado para petróleo (m^3) y para gas (miles de m^3): 4 modelos en total.

2. Feature engineering (src/ypf_ds/features/build.py)

Todas las variables dinámicas se calculan con datos hasta el mes t (shift y ventanas hacia atrás). Hay un test automático que modifica la producción futura de un pozo y verifica que sus features pasadas no cambien (ausencia de fuga de datos).

Grupo	**Variables (53 en el modo A)**
Historia	log1p de petróleo, gas y agua del mes y lags 1, 2, 3, 6, 12; medias móviles de 3 y 6 meses
Estado del pozo	pico histórico, producción/pico, meses desde el pico, acumulada, caudal por día efectivo, fracción de días producidos, tendencia de 3 meses, meses con producción 0 en los últimos 6
Fluidos	GOR y corte de agua del mes
Estáticas	formación, shale/tight, yacimiento, operadora, profundidad, latitud, longitud, año de inicio, fluido, sistema de extracción y estado
Modo B	formación, shale/tight, yacimiento, operadora, tipo de pozo, profundidad, lat/lon, año de inicio y mes de vida

3. Validación temporal

Nunca se entrena con el futuro: train hasta 2022, validación 2023 (para Optuna y la selección de variables) y test 2024–2025, usado una sola vez al final. En el modo B el corte es por año de inicio del pozo: los pozos de test nunca fueron vistos en el entrenamiento.

Modelo	**Filas train**	**Filas valid**	**Filas test**
petroleo_existente	1.587.854	290.501	713.822

gas_existente	2.035.250	363.032	850.222
petroleo_nuevo	73.107	8.345	16.203
gas_nuevo	73.107	8.345	16.203

4. Comparación de algoritmos

Con el mismo target (variación logarítmica), una muestra de 120.000 filas de entrenamiento y 60.000 de test, horizontes 1, 3, 6 y 12 (petróleo, modo A):

Modelo	R^2	WAPE	Tiempo (s)
Random Forest	0,731	0,381	49,9
KNN (k = 25)	0,728	0,392	1,8
Árbol de decisión	0,683	0,399	2,4
LightGBM	0,707	0,401	7,1
MLP (red neuronal)	0,700	0,413	3,3
XGBoost	0,692	0,413	4,1
Ridge	0,667	0,421	0,1
Persistencia (baseline)	0,439	0,528	—

Todos los modelos no lineales superan a la persistencia y quedan muy parejos. Random Forest sale apenas primero, pero tarda ~7 veces más que LightGBM. Se eligió LightGBM porque entrena sobre los 1,6 millones de filas reales en segundos, maneja categóricas y nulos de forma nativa, admite pesos y regresión por cuantiles y, con el target en volumen, supera a todos los modelos de la tabla.

5. Decisión clave: el target

Entrenar en log1p y volver con expm1 estima la mediana geométrica, no la media: por la desigualdad de Jensen, la producción total pronosticada queda sesgada a la baja.

Target (LightGBM, misma muestra)	R^2	WAPE	Sesgo (pred/real)
Variación logarítmica	0,707	0,401	0,812
Ratio ponderado por volumen	0,767	0,343	1,005

El modelo final del modo A predice el ratio $q[t+h]/q[t]$ con peso $q[t]^2$, que equivale a minimizar el error cuadrático en m^3. El modo B predice el volumen directamente, y Optuna elige el objetivo (L2, Poisson o Tweedie). Las bandas P10 y P90 se entrenan con regresión por cuantiles en escala log: los cuantiles no sufren el problema de Jensen.

6. Optimización de hiperparámetros

Comparación con el mismo presupuesto de 12 entrenamientos: GridSearch obtuvo un RMSE de validación de 1,1890 en 82 s y Optuna (TPE) 1,1870 en 77 s. La ventaja de Optuna crece con más hiperparámetros, porque la grilla crece exponencialmente. Los modelos finales usan Optuna con 20 intentos y early stopping sobre la validación 2023.

Modelo	Objetivo	learning_rate	num_leaves	min_child_samples	Árboles
petroleo_existente	regression	0,024	45	244	553

gas_existente	regression	0,027	98	344	281
petroleo_nuevo	regression	0,056	31	98	111
gas_nuevo	tweedie	0,162	65	72	25

7. Resultados en test (2024–2025)

7.1 Modo A — pozo existente (horizontes 1 a 12)

Modelo	MAE	RMSE	R^2	WAPE
Petróleo — LightGBM	215	537	0,730	0,369
Petróleo — persistencia	364	898	0,246	0,625
Gas — LightGBM	263	823	0,779	0,375
Gas — persistencia	377	1.191	0,536	0,539

7.2 Error según el horizonte

Horizonte	R^2 petróleo	R^2 persistencia pet.	R^2 gas	R^2 persistencia gas
1 mes	0,889	0,817	0,882	0,836
3 meses	0,745	0,503	0,793	0,614
6 meses	0,658	0,085	0,755	0,458
12 meses	0,630	-0,840	0,721	0,341

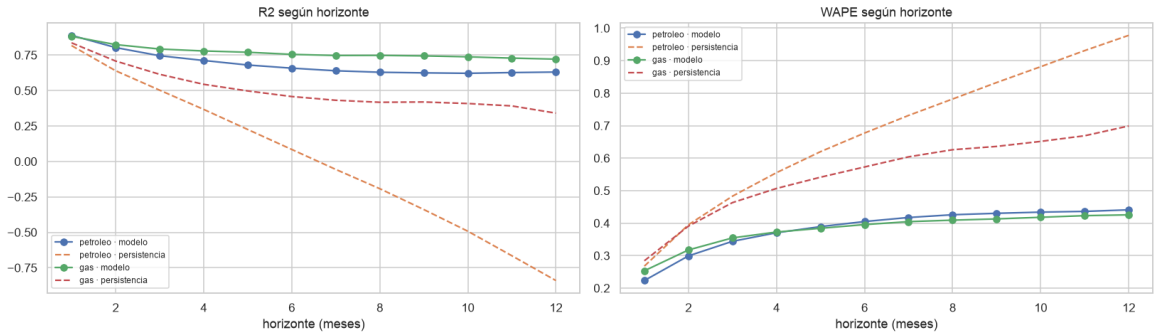


Figura 1. R^2 y WAPE por horizonte: el modelo mantiene su precisión donde repetir el último mes se derrumba.

7.3 Backtest contra la curva de declinación de Arps

Pronóstico a 12 meses desde diciembre de 2023 para todos los pozos activos. Arps hiperbólica se ajusta pozo por pozo con sus últimos 24 meses.

Fluido	Pozos	WAPE LightGBM	WAPE Arps	WAPE persistencia
Petróleo	2.291	0,357	0,583	0,665
Gas	2.724	0,385	0,474	0,518

7.4 Modo B — pozo nuevo (acumulada de los primeros 12 meses, 729 pozos de 2024–2025)

Modelo	MAE	R^2	WAPE
Petróleo — LightGBM	9.940	0,448	0,309
Petróleo — curva mediana	16.253	-0,282	0,505

Gas — LightGBM (Tweedie)	6.508	0,860	0,282
Gas — curva mediana	9.499	0,724	0,411

Cobertura de la banda P10–P90 (ideal 0,80): petróleo A 0,81, gas A 0,79, petróleo B 0,74, gas B 0,73.

8. Comparación con la versión anterior del proyecto

La versión 1 reportaba R^2 0,907, pero predecía solo un mes adelante, solo petróleo, solo en pozos con producción en los dos meses previos y mezclando cuencas. Medida con ese mismo alcance, la versión 2 obtiene:

Fluido	**R^2 v2 (mismo alcance que v1)**	**R^2 persistencia**	**R^2 global v2 (h 1–12)**
Petróleo	0,906	0,876	0,730
Gas	0,890	0,860	0,779

Los resultados son equivalentes a un mes (la v1 tenía 0,907 contra 0,878 de su baseline). La v2 agrega lo que la v1 no tenía: pronóstico a 12 meses, gas, bandas de incertidumbre y predicción para pozos nuevos.

9. Selección de variables del Capítulo IV

Modelo pozo nuevo	**RMSE valid. base**	**RMSE valid. + Capítulo IV**	**Elegido**
Petróleo	1.072,8	1.079,2	base
Gas	1.961,5	1.963,0	base

Las variables del Capítulo IV (pozo horizontal, días de perforación, días de terminación, cota) no mejoraron la validación: la profundidad medida, que en un pozo horizontal incluye la rama lateral, ya captaba esa información. La selección se repite automáticamente en cada reentrenamiento.

10. Explicabilidad (notebook 05)

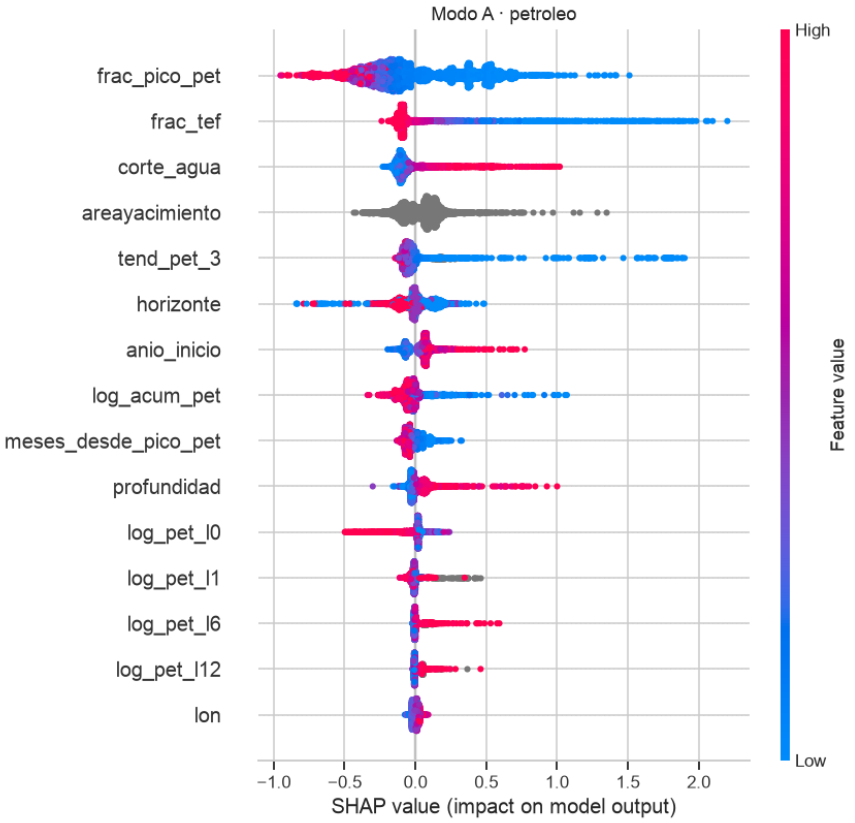


Figura 2. SHAP del modo A (petróleo).

- Modo A: dominan la posición respecto del pico (producción actual / pico histórico), la fracción de días producidos en el último mes (si fue parcial por una parada, el modelo espera una recuperación), la tendencia reciente y el horizonte; en petróleo pesan además el corte de agua y el yacimiento. El modelo aprendió la física de la declinación: un pozo en su pico solo puede bajar, y los pozos jóvenes declinan más rápido que los maduros.
- Modo B: pesan el mes de vida (la forma de la curva), la profundidad (en pozos horizontales incluye la rama lateral), el yacimiento, el tipo de pozo declarado, el año de inicio (proxy de tecnología de completación) y la ubicación.
- La API devuelve en cada predicción las 6 variables con mayor impacto (TreeSHAP nativo de LightGBM).

11. Limitaciones

- El modo B petróleo tiene R^2 0,45: el dataset público no incluye largo de rama lateral, etapas de fractura ni volumen de arena, que son los determinantes principales de la productividad de un pozo nuevo.
- Las paradas, las reparaciones y las restricciones de transporte no están en los datos.
- La productividad mejora año a año (drift tecnológico): hay que reentrenar periódicamente.