Pre-Entrega 3 — Feature Engineering y Modelado Supervisado

Proyecto Final Integrador — Data Science 2026

Alumnos	Cristian Alejandro Aguilera, Abigail Roxana Vicentelo, Ian Lionel Tapias Díaz
Programa	Data Science 2026 (Fundación YPF - Jump)
Repositorio GitHub	https://github.com/cristian-aguilera-ing/proyecto-ds-ypf.git

1. Feature Engineering (notebooks/02_feature_engineering.ipynb)

Sobre el dataset limpio de la Pre-Entrega 2, se construyeron variables derivadas orientadas a capturar el comportamiento temporal de cada pozo. Todas se calculan en meses de calendario:

Variable	Descripción
antiguedad_meses	Meses de calendario desde el primer mes con datos del pozo (1 = primer mes registrado)
prod_pet_mes_anterior / prod_gas_mes_anterior	Producción del mes anterior (lag), por pozo. Queda vacía en el primer mes y después de un hueco
declinacion_pet / declinacion_gas	% de variación respecto del mes anterior
ratio_gas_petroleo	Relación gas/petróleo del mes
prod_pet_hace_2_meses / declinacion_pet_anterior / ratio_gas_petroleo_anterior	Variables del mes anterior para el modelo (no contienen la producción del mes a predecir)
prod_pet_acumulada / prod_gas_acumulada	Producción acumulada del pozo hasta ese mes
formacion_cod / cuenca_cod	Codificación numérica de formacion y cuenca

Corrección posterior: una revisión del equipo detectó que 704 de los 5.089 pozos tienen meses sin fila (831 huecos, 7.421 meses en total) y que contar filas atrasaba la antigüedad en el 17,3% de las filas del dataset (14,7% del período de prueba). Se corrigió usando meses de calendario: la antigüedad cuenta meses y, después de un hueco, las variables del mes anterior quedan vacías en lugar de copiar un mes lejano. Todas las cifras de este documento corresponden al dataset corregido.

2. Diseño del Experimento de Modelado

- Variable objetivo: prod_pet (producción mensual de petróleo por pozo).
- Modelos: XGBoost (XGBRegressor) y LightGBM (LGBMRegressor), parámetros base equivalentes (n_estimators=200, max_depth=5, learning_rate=0.1).
- Separación train/test respetando el tiempo (no aleatoria): entrenamiento con años anteriores a 2024, prueba con 2024-2025.

- Se excluyeron del entrenamiento el primer mes de cada pozo (sin "mes anterior" disponible) y el año 2026 (incompleto). Desde la sección 11, el modelo trabaja con un alcance explícito.

3. Iteración 1 — Modelo Base (7 features, XGBoost)

Features: antiguedad_meses, prod_pet_mes_anterior, prod_gas_mes_anterior, ratio_gas_petroleo, profundidad, formacion_cod, cuenca_cod.

Resultado: MAE 194,70 — RMSE 518,04 — R^2 0,854. Buen ajuste en el rango bajo-medio de producción, pero subestimación sistemática de los pozos con picos muy altos (>10.000).

4. Iteración 2 — Fuga de Datos Detectada y Descartada

Se intentó agregar declinacion_pet (variación % respecto del mes actual). El R^2 subió a 0,979 — un salto sospechoso.

Diagnóstico: declinacion_pet se calcula como (prod_pet − prod_pet_mes_anterior) / prod_pet_mes_anterior. La variable objetivo queda embebida en la fórmula de la propia feature, por lo que prod_pet se puede despejar algebraicamente. El modelo no predecía: recibía la respuesta disfrazada. Descartada.

5. Iteración 3 — Modelo Corregido (8 features, XGBoost)

Se reemplazó la variable con fuga por declinacion_pet_anterior (declinación del mes anterior — sin fuga).

Resultado: MAE 162,33 — RMSE 441,70 — R^2 0,887. Mejora real y modesta. El problema de subestimación de picos altos persistía.

6. Iteración 4 — Máximo Histórico del Pozo (Descartada)

Se agregó prod_pet_maxima_anterior (máximo histórico de producción del pozo, calculado solo con datos hasta el mes anterior, sin fuga de datos).

Resultado: MAE 163,98 — RMSE 436,11 — R^2 0,890. Mejora chica (RMSE 436,11 contra 441,70) y el error en picos sigue muy alto (4.587,8). Descartada para no sumar una variable por una ganancia marginal que no resuelve el problema de los picos.

7. Iteración 5 — Log-transform del Objetivo (Descartada)

Se entrenó el modelo sobre log(1 + prod_pet) en vez del valor directo (con las 9 features), buscando atenuar el sesgo hacia los valores bajos.

Resultado: MAE 160,90 — RMSE 462,44 — R^2 0,876. Mejoró apenas el MAE, pero el RMSE y el error en picos (6.008,9) empeoraron y aparecieron sobreestimaciones extremas, por la amplificación del error al revertir el logaritmo. Descartada por introducir un problema más grave que el original.

8. Iteración 6 — Comparación XGBoost vs. LightGBM

La Pre-Entrega 1 especificaba entrenar y comparar modelos de regresión (XGBoost / LightGBM). Se entrenó LightGBM con las mismas 8 features de la Iteración 3, el mismo split temporal y parámetros equivalentes, para una comparación justa.

Métrica	XGBoost	LightGBM
MAE	162,33	163,27
RMSE	441,70	440,63
R^2	0,887	0,887
Error en picos altos (>10.000)	5.090,8	4.996,9

Resultado: empate técnico: LightGBM tiene una ventaja marginal en el RMSE y en el error en picos, y XGBoost una leve ventaja en el MAE. Se adopta LightGBM como modelo principal, conservando ambos modelos por separado para trazabilidad.

Nota metodológica: los gráficos de importancia de variables de XGBoost (escala 0-1, basada en gain) y LightGBM (escala 0-1000, basada en split por defecto) usan métricas distintas y no son directamente comparables — la diferencia de escala no implica que un modelo haya "entendido mejor" los datos. Ambos coinciden en que prod_pet_mes_anterior es la variable dominante.

9. Tabla Comparativa de las Iteraciones 1 a 6

Métrica	Base	Con fuga (desc.)	+ máxima (desc.)	Log-transf. (desc.)	XGBoost (it. 3)	LightGBM (it. 6)
MAE	194,70	37,63	163,98	160,90	162,33	163,27
RMSE	518,04	196,97	436,11	462,44	441,70	440,63
R^2	0,854	0,979	0,890	0,876	0,887	0,887
Error en picos (>10.000)	4.835	2.411	4.588	6.009	5.091	4.997

Estas iteraciones se reentrenan por código en el notebook 03, por lo que la tabla siempre refleja los datos actuales. El modelo de la Iteración 6 fue superado por las iteraciones 7 a 9 (secciones 12 a 14).

10. Limitación Conocida

En todas las versiones de las iteraciones 1 a 6 (XGBoost y LightGBM por igual), el modelo subestima los pozos con picos de producción muy altos (posibles eventos de reestimulación/refractura). Se probaron tres enfoques distintos para resolverlo (una variable nueva, un cambio de objetivo de entrenamiento, y un segundo algoritmo) y ninguno lo resolvió de fondo. En ese momento se atribuyó el problema a la ausencia de una variable que el dataset no incluye (por ejemplo, si se programó una intervención en el pozo). La evidencia posterior agregó una causa verificable, ver la sección 16. Se documenta como limitación conocida.

El modelo LightGBM de 8 variables (Iteración 6) se guardó en models/modelo_produccion_pet_lightgbm.joblib. **Nota posterior:** fue reemplazado como modelo principal por el de la Iteración 9 (secciones 12 a 16), porque usaba una variable con fuga de datos.

11. Alcance del Modelo

Hasta la Iteración 6, el filtro automático de datos faltantes decidía sin declararlo con qué filas trabajaba el modelo. Una observación del equipo (Abigail Vicentelo) lo hizo explícito: el modelo final **predice la producción de petróleo del mes siguiente de un pozo que produjo petróleo en los dos meses previos** (meses de calendario consecutivos). Es la misma definición que exige la API. En el período de prueba (102.663 filas):

Categoría	Filas	% del período
En alcance (petróleo en los 2 meses previos)	65.574	63,9%
Mes anterior en 0 y sigue en 0	32.012	31,2%
Mes anterior con petróleo, pero hace 2 meses sin petróleo	2.313	2,3%
Mes anterior en 0 y retoma la producción	1.624	1,6%
Sin mes anterior (primer mes del pozo o tras un hueco)	1.140	1,1%

Cobertura: el alcance incluye el 93,5% de los meses con producción de petróleo mayor a 0 (64.364 de 68.842); la mayoría de las filas que quedan afuera son meses con petróleo en 0 (pozos gasíferos o parados). No se filtra por el tipo de pozo (tipopozo) porque ese campo cambia con el tiempo en muchos pozos y hay meses con petróleo en pozos clasificados como gasíferos.

Prueba de ampliar el alcance: se probó incluir también las retomas y los meses en 0 (alcanza con tener mes anterior). En las filas del alcance no mejora (MAE 159,1 contra 158,7); en las retomas supera al baseline (349,3 contra 399,1), pero con un error alto; y en los meses que siguen en 0 predice algo de petróleo donde no hay (13,2 de error medio, contra 0 del baseline). Se decidió no ampliar el alcance: los meses en que un pozo retoma la producción se documentan como limitación.

12. Iteración 7 — Fuga de Datos en ratio_gas_petroleo (Detectada y Corregida)

Al aplicar SHAP, ratio_gas_petroleo apareció como una de las variables más importantes. Al revisar su definición se verificó que **ratio_gas_petroleo = prod_gas / prod_pet del mismo mes que se quiere predecir** (coincide en el 100% de las filas): la producción de petróleo a predecir queda en el denominador, de modo que el modelo puede aproximar la respuesta. Además, ese dato no existe al momento de predecir el mes siguiente, por lo que el modelo no era utilizable en la API tal como estaba planteado.

Corrección: se reemplazó por ratio_gas_petroleo_anterior (ratio del mes anterior). Las iteraciones 1 a 6 usaban la versión con fuga; sus comparaciones relativas siguen siendo válidas, pero ese modelo ya no es el vigente. Se incorporó además un **baseline** simple, que predice que cada mes produce lo mismo que el mes anterior, para medir el aporte real del modelo.

Métrica	Baseline (mes anterior)	LightGBM Iteración 6 (con fuga)*	LightGBM Iteración 7 (sin fuga)
MAE	170,92	163,27	163,36
RMSE	456,92	440,63	432,64
R^2	0,878	0,887	0,891
Error medio en picos	1.996,5	4.996,9	4.588,5

(>10.000)			

*La Iteración 6 se evaluó sobre 64.957 filas de prueba; el baseline y la Iteración 7 sobre 65.574, las del alcance. **Resultado:** corregir la fuga no empeora el modelo (mejora), y el modelo supera al baseline por un margen modesto. En los picos altos, repetir el mes anterior sigue siendo mejor que el modelo.

13. Iteración 8 — Predecir la Variación en lugar del Nivel

SHAP mostró que el modelo se apoya en prod_pet_mes_anterior y que, en los picos, su aporte se aplana. Los modelos de árboles no pueden predecir por encima de lo que vieron al entrenar: el máximo de producción en entrenamiento (hasta 2023) fue 15.943, con solo 36 filas sobre 10.000 entre 170.927, mientras que en el período de prueba hay picos de hasta 26.593.

Se cambió el objetivo: el modelo predice **cuánto cambia la producción respecto del mes anterior** (prod_pet − prod_pet_mes_anterior), y la predicción final se obtiene sumando ese cambio al mes anterior y recortando en 0 (3.080 de las 65.574 predicciones, el 4,7%, eran negativas antes del recorte).

Métrica	Baseline (mes anterior)	LightGBM Iteración 7	LightGBM Iteración 8 (variación)
MAE	170,92	163,36	**158,75**
RMSE	456,92	432,64	**408,75**
R^2	0,878	0,891	**0,903**
Error medio en picos (>10.000)	1.996,5	4.588,5	3.032,2

Resultado: mejora las cuatro métricas respecto de la Iteración 7 y reduce el error en picos, aunque sigue siendo peor que el baseline en los meses de producción extrema.

14. Iteración 9 — Optimización de Hiperparámetros con Optuna (notebooks/06_optimizacion_optuna_dl.ipynb)

Hasta acá todos los modelos usaron los mismos parámetros base (n_estimators=200, max_depth=5, learning_rate=0,1). Se buscó una mejor combinación con Optuna sobre el modelo de la Iteración 8, **sin usar el período de prueba para elegir**: los parámetros se eligieron con una validación temporal dentro del entrenamiento (tres rondas que entrenan con los años anteriores y validan con 2021, 2022 y 2023, nunca con datos posteriores) y el período de prueba (2024-2025) se usó una sola vez, al final.

- Se probaron 40 combinaciones de: cantidad de árboles, learning rate, profundidad, cantidad de hojas, mínimo de filas por hoja, submuestreo de filas y de variables, y regularización.
- El puntaje de cada combinación es el RMSE promedio de las tres rondas de validación: 319,83 con los mejores parámetros contra 331,72 con los parámetros base.

Métrica	Baseline (mes anterior)	Iteración 8 (parámetros base)	Iteración 9 (optimizada)
MAE	170,92	158,75	**154,26**

RMSE	456,92	408,75	**398,75**
R^2	0,878	0,903	**0,907**
Error medio en picos (>10.000)	1.996,5	3.032,2	2.560,6

Chequeo de overfitting: el modelo optimizado tiene un error algo mayor en entrenamiento (RMSE 235,98 contra 213,03) y menor en prueba (398,75 contra 408,75), por lo que la brecha entre prueba y entrenamiento baja de 195,72 a 162,77. Es decir, el modelo se volvió más regularizado y no más memorizador.

Resultado: mejora modesta pero consistente (≈ 2,4% de RMSE), sin agrandar la brecha, por lo que se adopta como modelo final. Aun así, en los picos extremos el baseline de repetir el mes anterior sigue siendo mejor. Nota de método: los hiperparámetros se eligieron sin mirar el período de prueba, pero las decisiones de diseño de las iteraciones 7 y 8 sí se tomaron observando resultados en ese período.

15. Explicabilidad con SHAP (notebooks/05_explicabilidad_shap_dl.ipynb)

Se aplicó SHAP al modelo final. Como el modelo predice la variación respecto del mes anterior, los valores SHAP explican esa variación: positivo significa que la variable empuja la producción por encima de la del mes anterior.

- **Variable dominante:** prod_pet_mes_anterior (SHAP promedio de 75,1), seguida de profundidad (44,3) y antiguedad_meses (23,2). Cuanto más produjo el pozo el mes anterior, más baja la variación predicha: el modelo aprendió que los pozos muy productivos tienden a declinar.
- **Dirección del efecto:** la antigüedad aporta sobre todo en los primeros meses de vida del pozo (el arranque de la producción); una declinación previa alta suma (inercia); un gas alto del mes anterior resta; y la profundidad suma a partir de unos 5.000 m, probablemente porque los pozos profundos son los modernos de Vaca Muerta (una asociación, no una causa).
- **Variables de poco aporte:** formacion_cod (1,07) y cuenca_cod (0,00) casi no mueven la predicción.
- **Picos altos:** en los 60 meses con producción real mayor a 10.000 la variación real promedio fue de 1.996,5 y la predicha de -564,1: el modelo espera que un pozo muy productivo decline, pero estos meses son justamente aquellos en que la producción subió mucho. En el caso más subestimado (pozo 164941) el mes anterior fue 12.514, el modelo predijo 10.827 y la producción real fue 24.539.

16. Modelo Final Vigente y Limitación Revisada

Modelo final: LightGBM (Iteración 9: iteración 8 con hiperparámetros optimizados), con las 8 variables antiguedad_meses, prod_pet_mes_anterior, prod_gas_mes_anterior, declinacion_pet_anterior, ratio_gas_petroleo_anterior, profundidad, formacion_cod y cuenca_cod. Predice la variación respecto del mes anterior: la producción se obtiene como prod_pet_mes_anterior + variación predicha, con piso en 0. Métricas en el período de prueba: MAE 154,26 — RMSE 398,75 — R^2 0,907.

- models/modelo_produccion_pet.joblib: modelo principal vigente. Reemplaza al guardado en la Pre-Entrega 3.
- models/columnas_features.joblib: lista de variables que espera el modelo (para la API).
- models/modelo_produccion_pet_lightgbm_v7.joblib, models/modelo_produccion_pet_lightgbm_v8.joblib y models/modelo_produccion_pet_optuna.joblib: versiones de las iteraciones 7, 8 y 9; los hiperparámetros elegidos están en models/mejores_parametros_optuna.json.
- Los modelos XGBoost y LightGBM de las secciones 8 y 9 se conservan solo por trazabilidad: usan la variable con fuga.

Limitación revisada: en la sección 10 se atribuía la subestimación de picos a la ausencia de una variable de intervención. La evidencia posterior agrega una causa verificable: el modelo casi no vio producciones altas al entrenar y los árboles no extrapolan (máximo de 15.943 en entrenamiento contra 26.593 en prueba). Además, los meses de pico se eligen justamente por haber producido mucho, y el modelo no puede anticipar saltos como los del caso más subestimado. Las explicaciones pueden coexistir; la hipótesis de reestimulación no se confirma ni se descarta con los datos disponibles. En los picos extremos, repetir el mes anterior sigue siendo mejor que el modelo, y se documenta como limitación aceptada.

17. Próximos Pasos

- Entrega Final: la API (FastAPI), el frontend de pruebas y el Docker Compose están armados y funcionando; falta cerrar el README final y la presentación oral.
- Mejoras posibles: ajustar curvas de declinación tipo Arps, y estudiar el alcance de las retomas de producción con una variable que indique intervenciones en el pozo, si estuviera disponible.