Pre-Entrega 4 — Modelado No Supervisado (Clustering)

Proyecto Final Integrador — Data Science 2026

Alumnos	Cristian Alejandro Aguilera, Abigail Roxana Vicentelo, Ian Lionel Tapias Díaz
Programa	Data Science 2026 (Fundación YPF - Jump)
Repositorio GitHub	https://github.com/cristian-aguilera-ing/proyecto-ds-ypf.git

1. Objetivo y Enfoque (notebooks/04_modelado_no_supervisado_dl.ipynb)

Se agruparon los pozos no convencionales según su comportamiento productivo, para entender si existen familias de pozos distintas entre sí y revisar si los pozos con picos de producción muy altos (la limitación del modelo supervisado de la Pre-Entrega 3) forman un grupo propio.

- **Algoritmo elegido:** K-Means (init k-means++, n_init=10, random_state=42), sobre variables escaladas con StandardScaler. Criterio: es interpretable (el centro de cada cluster se traduce directamente en un perfil de pozo) y eficiente para unos 4.300 pozos. Su debilidad (sensibilidad a valores extremos) condicionó las correcciones de las secciones 3 y 4.
- **Unidad de análisis:** un pozo = una fila, resumido en 4 variables: pico_prod_pet (máximo histórico), declinacion_promedio (declinación mensual típica, calculada con declinacion_pet_anterior para evitar la fuga de datos de la Pre-Entrega 3), antiguedad_total (meses de calendario de historia) y ratio_gas_pet_promedio.
- **Alternativa descartada:** ajustar curvas de declinación tipo Arps pozo por pozo. Es más fiel físicamente, pero costosa de ajustar y de explicar en el tiempo disponible; queda como mejora futura.

2. Análisis Exploratorio de las Variables por Pozo

Antes de agrupar se examinó la distribución de las 4 variables sobre los 4.343 pozos resultantes del primer resumen (con promedios). Estas cifras corresponden a esa primera corrida, anterior a las correcciones descritas más abajo:

Variable	Mediana	Percentil 90	Percentil 99	Máximo
pico_prod_pet	1.494	7.116	10.960	26.593
declinacion_promedio	0,25	4,07	210,7	839.564
antiguedad_total	79	153	247	247
ratio_gas_pet_promedio	0,79	207,6	3.670,5	1.339.944

Hallazgos: la declinación y el ratio gas/petróleo tienen colas extremas (el máximo es miles de veces la mediana), porque son cocientes que se disparan cuando el denominador está cerca de cero. Además, 48 pozos tienen un pico menor a 1, es decir, casi no produjeron petróleo.

3. Primera Versión — Resultado Engañoso (Descartado)

Con k = 4, **dos de los cuatro clusters tenían un solo pozo**: el pozo 162450 (pico de 0,005 y ratio gas/petróleo de 1.339.944) y el pozo 137343 (declinación promedio de 839.563). El silhouette de 0,542 era engañoso: estaba inflado por esos dos puntos aislados, y el gráfico PCA mostraba los 4.341 pozos restantes aplastados en una línea. Los otros dos clusters (2.396 y 1.945 pozos) tenían estructura, pero sus promedios estaban contaminados por los valores extremos.

Revisión: en lugar de cerrar con un k que "daba bien" en las métricas, se corrigió el origen del problema (ver sección 4).

4. Mejoras Aplicadas

Problema detectado	Corrección
48 pozos con pico menor a 1 generan ratios absurdos	Se filtran los pozos con pico_prod_pet menor a 1 (4.343 → **4.295** pozos)
El promedio es muy sensible a valores extremos	Se usa la mediana en declinacion_promedio y ratio_gas_pet_promedio
La declinación no tiene techo (su piso natural es -1: la producción cae a cero)	Se recorta entre -1 y el percentil 99 (≈ 4,46)
pico_prod_pet y el ratio tienen cola muy larga	Se aplica log1p a ambas
Las variables están en escalas distintas	StandardScaler (media 0, desvío 1)

Cobertura: el dataset tiene 5.089 pozos únicos y el clustering usa 4.295. Quedaron afuera pozos que nunca produjeron petróleo (gasíferos puros, con ratio gas/petróleo no definido) y pozos con muy poca historia o producción casi nula. Es una decisión de diseño: se agrupan pozos con producción real de petróleo.

5. Elección de k

k	Inercia	Silhouette
2	10.367	0,448
3	6.857	0,482
4	**4.479**	**0,473**
5	3.829	0,453
6	3.205	0,449
7	2.868	0,442
8	2.588	0,452

El método del codo marca **k = 4** (la inercia cae fuerte de 3 a 4 y después se aplana). El silhouette es máximo en k = 3 (0,482), pero la diferencia con k = 4 (0,473) es chica, por lo que se priorizó el k que separa grupos más fáciles de explicar físicamente.

6. Resultados — Perfil de los Clusters

Valores típicos (mediana) con las variables originales, sin logaritmo ni recorte:

Interpretación	Pozos	Pico prod_pet	Antigüedad (meses)	Ratio gas/pet
Modernos de alta producción de petróleo (tipo Vaca Muerta)	2.038	5.251	33	0,14
Viejos de producción media	1.087	795	142	1,04
Viejos con mucho gas y casi nada de petróleo	1.095	53	104	54,76
Recién puestos en producción (75 pozos; 71 con 10 meses de historia o menos)	75	6.053	3	0,20

La declinación típica es casi igual en los tres clusters grandes (entre -0,02 y -0,04), por lo que aporta poco para separarlos; los diferencian el pico, la antigüedad y el ratio. El cluster de pozos recién puestos en producción se distingue por esa variable (mediana de 6,76) porque, con tan poca historia, su "declinación" es en realidad el crecimiento de arranque. En 50 de sus 75 pozos el pico es el último mes registrado, es decir que todavía están subiendo.

7. Validación Visual

- **PCA en 2D:** los dos componentes explican ≈ 79% de la información (54% + 24%). Tres clusters forman un continuo (de pozos chicos y gasíferos a pozos grandes y modernos) que K-Means corta en tramos, con solapamiento en los bordes; el cluster de pozos recién puestos en producción se separa claramente. El clustering segmenta una gradación de pozos, no descubre grupos totalmente aislados.
- **Curvas representativas** (pozo más cercano al centro de cada cluster): tienen sentido físico. El pozo viejo con gas (159285) es una curva casi chata cerca de cero; el de producción media (145719) sube a un pico de 655 en el mes 8 y declina hasta unos 34; el moderno (164529) llega a 4.374 en el mes 5 y baja a unos 1.100 al mes 36; el recién puesto (167147) sube a 6.413 en el mes 3, con solo 5 meses de historia.

8. Cruce con la Limitación del Modelo Supervisado

De los **94 pozos con pico mayor a 10.000**, 88 caen en el cluster de pozos modernos de alta producción y 6 en el de pozos recién puestos en producción. Es coherente con que son los pozos más productivos, pero no revela un subgrupo distinto: el cluster de pozos modernos es grande y la información que aporta es limitada. El clustering **no confirma ni descarta** la hipótesis de reestimulación como causa de la subestimación del modelo supervisado.

9. Decisiones Tomadas y Criterio Aplicado

Decisión	Criterio

Resumir cada pozo en 4 variables	Mantener coherencia con las features del modelo supervisado y poder explicar cada variable
Mediana en lugar de promedio	Robustez frente a cocientes que se disparan con denominadores cercanos a cero
Filtrar pozos con pico menor a 1	El ratio gas/petróleo no tiene sentido sin producción de petróleo
Recortar la declinación entre -1 y el percentil 99	Respetar su piso natural y evitar que pocos casos dominen la distancia
Elegir k = 4 y no k = 3	Diferencia de silhouette menor a 0,02; se prioriza interpretabilidad para la defensa
Descartar Arps	Costo de ajuste y explicación superior al tiempo disponible

10. Limitaciones

- El silhouette (≈ 0,47) indica una estructura moderada: hay grupos reales, pero se solapan en parte.
- declinacion_promedio casi no separa los clusters grandes. Una mejora futura sería ajustar curvas de Arps por pozo.
- Los pozos gasíferos puros y los de muy poca historia quedan fuera del análisis.

11. Archivos Generados

- data/processed/pozos_con_cluster.csv: pozos con su cluster y valores originales.
- models/modelo_clustering_kmeans.joblib y models/scaler_clustering.joblib: modelo y scaler entrenados.
- models/tope_declinacion_clustering.joblib: tope del recorte de declinación, necesario para asignar un cluster a un pozo nuevo (recorte, logaritmo y escalado, en ese orden).

12. Próximos Pasos

- Cerrar la Entrega Final: README, presentación oral y repositorio. La explicabilidad (SHAP), la optimización de hiperparámetros (Optuna), la API (FastAPI), el frontend de pruebas y el Docker Compose ya están hechos.