

Pre-Entrega 1 — Definición del Problema y Dataset

Proyecto Final Integrador — Data Science 2026

Alumnos	- Cristian Alejandro Aguilera - Abigail Roxana Vicentelo - Ian Lionel Tapias Díaz
Programa	Data Science 2026 (Fundación YPF - Jump)
Fecha de entrega	7 de septiembre de 2026
Repositorio GitHub	https://github.com/cristian-aguilera-ing/proyecto-ds-ypf.git

1. Definición del Problema

1.1 Título del proyecto

Predicción y Optimización de la Producción de Hidrocarburos No Convencionales (Vaca Muerta / YPF).

1.2 Planteamiento del problema

La producción de petróleo y gas en yacimientos no convencionales (shale/tight) presenta curvas de declinación pronunciadas y heterogéneas entre pozos, condicionadas por variables geológicas (formación, profundidad, cuenca) y de completación. Anticipar el comportamiento productivo de un pozo a partir de estas variables permite optimizar la planificación de perforación, la asignación de recursos de fractura y la proyección de reservas.

El proyecto busca predecir la producción mensual de petróleo y gas de pozos no convencionales de la cuenca Neuquina a partir de sus atributos geológicos y de ubicación, y complementar ese análisis con una segmentación no supervisada de pozos según su perfil de producción.

1.3 Objetivos

- Objetivo general: construir un pipeline de Data Science reproducible que permita predecir la producción de pozos no convencionales y agrupar pozos según su comportamiento productivo.
- Objetivo específico (supervisado): entrenar y comparar modelos de regresión (XGBoost / LightGBM) para estimar la producción mensual de petróleo y gas por pozo.
- Objetivo específico (no supervisado): aplicar clustering (K-Means) para agrupar pozos según sus curvas de declinación.
- Objetivo específico (explicabilidad): identificar, mediante SHAP, qué variables geológicas y de completación influyen más en la producción estimada.
- Objetivo específico (producto): exponer el modelo entrenado a través de un endpoint REST (FastAPI) que reciba parámetros de un pozo y devuelva una estimación de producción.

1.4 Relevancia

Vaca Muerta es el principal proyecto de hidrocarburos no convencionales de Argentina y un eje central de la estrategia energética de YPF. Contar con estimaciones tempranas de producción por pozo aporta valor concreto a la planificación operativa y de inversión, y constituye un caso de aplicación real de ciencia de datos en el sector energético.

2. Selección del Dataset

2.1 Fuente

Se utiliza el dataset público "Producción de petróleo y gas por pozo (Capítulo IV)", publicado por la Secretaría de Energía de la Nación Argentina en el portal de datos abiertos.

Nota: Copiar y pegar en el navegador el siguiente link para la descarga automática del Dataset:

<http://datos.energia.gob.ar/dataset/c846e79c-026c-4040-897f-1ad3543b407c/resource/b5b58cdc-9e07-41f9-b392-fb9ec68b0725/download/produccion-de-pozos-de-gas-y-petroleo-no-convencional.csv>

2.2 Recurso utilizado

Del conjunto de recursos disponibles en el dataset, se seleccionó el archivo "Producción de Pozos de Gas y Petróleo No Convencional", que viene pre-filtrado a la población de interés (pozos shale/tight), evitando tener que segmentarlos manualmente del universo total de pozos convencionales y no convencionales del país.

2.3 Descripción general

Filas	421.046
Columnas	40 (39 tras la limpieza inicial)
Cobertura temporal	2006 – 2026 (mensual, por pozo)
Nivel de granularidad	Un registro por pozo, año y mes
Variables clave	idpozo, formacion, profundidad, cuenca, provincia, prod_pet, prod_gas, prod_agua, tipo_de_recurso, sub_tipo_recurso
Licencia	CC-BY-4.0

2.4 Justificación de la elección

- Es un dataset oficial, público y de actualización periódica, lo que garantiza trazabilidad de la fuente.
- Ya incluye los metadatos geológicos y de ubicación del pozo (formación, profundidad, cuenca) sin necesidad de cruzar con otra tabla para las variables mínimas del modelo.
- Cubre 20 años de historia, con volumen suficiente (421 mil registros) para entrenar modelos de regresión con capacidad de generalización.
- Presenta anomalías reales de calidad de datos (nulos, valores fuera de rango, producción negativa), lo que permite aplicar y documentar un proceso genuino de limpieza — no un dataset artificialmente prolijo.

3. Configuración Inicial del Repositorio

3.1 Repositorio

<https://github.com/cristian-aguilera-ing/proyecto-ds-ypf.git>

3.2 Estructura definida

Se adoptó la estructura estándar propuesta por la cátedra, separando responsabilidades por carpeta:

- data/raw/ — datos crudos originales, inmutables.
- data/processed/ — datos transformados, listos para modelado.
- notebooks/ — 01_eda_limpieza, 02_feature_engineering, 03_modelado_supervisado, 04_modelado_no_supervisado_dl.
- src/ — módulos de código reutilizable: data_loader.py, preprocessor.py, train.py, predict.py.
- api/ — app.py y schemas.py para el servicio FastAPI de la Entrega Final.
- models/ — artefactos serializados del pipeline entrenado (.joblib).
- reports/ — materiales para la defensa final.
- Dockerfile, requirements.txt y README.md en la raíz del proyecto.

3.3 Entorno de desarrollo

Se configuró un entorno virtual (venv) aislado del sistema operativo para gestionar las dependencias del proyecto, evitando conflictos con otras instalaciones de Python en la máquina de trabajo. Las dependencias se registran de forma incremental en requirements.txt a medida que se incorporan al pipeline.

4. Estado Actual y Próximos Pasos

Al momento de esta entrega, además de la definición del problema, la elección del dataset y la configuración del repositorio, ya se avanzó sobre el trabajo correspondiente a la Pre-Entrega 2: se implementó el módulo de ingesta y validación de datos (data_loader.py), se realizó el Análisis Exploratorio de Datos (01_eda_limpieza.ipynb) y se construyó el pipeline de limpieza (preprocessor.py), verificando numérica y visualmente la corrección de las anomalías detectadas (valores de profundidad fuera de rango, producción negativa y nulos por falta de carga).

Los próximos pasos del proyecto son:

- Feature engineering (02_feature_engineering.ipynb): variables derivadas de declinación, edad de pozo y codificación de variables categóricas.
- Modelado supervisado (Pre-Entrega 3): entrenamiento y optimización con Optuna, explicabilidad con SHAP.
- Modelado no supervisado (Pre-Entrega 4): clustering de curvas de declinación.
- Entrega Final: API en FastAPI, Dockerfile y documentación completa en README.md.